

뇌종양 진행률/예후 예측

캡스톤 최종 발표 (2025.06.11)

6팀 (민휘원, 박지호, 배영민, 손동희, 홍창희)



Contents

01. 문제 정의 및 목표

02. 데이터 전처리

03. CNN 모델 설계 & 결과

04. 강화 학습 & 결과

05. 기존 연구와의 비교




1. 문제 정의 및 목표


문제점: 현재 대부분의 임상 환경에서는 단일 시점의 MRI 영상을 바탕으로만 뇌종양을 진단, 평가함.
이 방식으로는 뇌 종양의 **잠재적 성장 속도**를 알아내기 어려워
환자의 **예후**가 어떨지 정량적으로 예측하기 어려움.

>> 환자의 뇌 종양 진행을 예측하는 모델을 구현하고자 함

- 일정 기간 이후의 종양 부피를 수치적으로 예측하는 Regression 모델을 구현하는데, CNN, 강화학습 두 가지 접근법을 시도함



Volume = 8,053 mm³




Volume = 20,806 mm³

2. 데이터 전처리



- 사용한 데이터셋: Brain-Tumor-Progression

- 한 명의 환자에 대해 두 시점의 MRI(flair, t1, t1ce, t2, mask)가 담긴 데이터셋 (20명)

1991-11-19




1992-04-02




2. 데이터 전처리


- 슬라이스 수 조절 - 환자마다 z축 슬라이스 수가 22~25개로 다양했기 때문에, 22개로 고정
- 리샘플링 - 이미지의 픽셀 간격이 1mm가 되도록 작업
- 정규화 - 픽셀 값들의 범위가 너무 크지 않도록, 픽셀 값들이 정규분포를 따르도록 정규화
- 정합(Registration) - 두 시점 세션의 MRI 이미지에서 뇌가 차지하는 좌표가 동일하지 않으므로 (각도, 크기, 위치의 불일치) 서로 매칭시켜 같은 좌표로 정렬함



Session 1



Session 2




Registered
Session 2



3. CNN 모델 설계 & 결과

모델 구조

- 사전학습된 ResNet-50을 사용
- ResNet 첫 Conv 레이어를 기존 3채널에서 5채널로 확장하여 Flair, T1ce, T1, T2, Mask를 input으로 사용
- 레이어를 확장하였기 때문에 기존 3채널 가중치를 평균에서 5채널로 재초기화
- ResNet-50의 fc 계층 제거 후 두 개의 separate head(size head, growth head) 추가
- 공유된 특징 추출기와 2개의 Head를 가지는 멀티태스크 구조



3. CNN 모델 설계 & 결과

학습 방법


- GroupShuffleSplit을 통해 환자 단위로 데이터를 train/validation/test로 분할
- flip, rotation 등 랜덤 augment 적용
- Rare Sample Weighting:
 - 예측이 어려운(값이 분포의 극단에 있는) 샘플에 더 큰 가중치 부여
 - cosine schedule을 통해 에폭이 진행될수록 점진적으로 강조

손실함수

- Multitask Loss:
 - size_loss: MSELoss
 - growth_loss: HuberLoss
- Weighted Loss 계산: $\text{size_loss} * \text{size_weight} + 0.6 * \text{growth_loss} * \text{growth_weight}$

3. CNN 모델 설계 & 결과

성능평가



4. 강화 학습 & 결과

강화학습이란? (What is Reinforcement Learning?)


- 에이전트(Agent)가 환경(Environment)과 상호작용하며 보상(Reward)을 최대화하는 방향으로 행동(Action)을 학습하는 과정.
- 명시적인 정답 라벨 없이 시행착오를 통해 학습.

주요 구성 요소 (Key Components)

- **에이전트 (Agent):** 결정 주체 (볼륨 예측 모델)
- **환경 (Environment):** 환자 슬라이스 데이터
- **상태 (State):** 현재 환자 및 슬라이스 특성
- **행동 (Action):** 볼륨 조정 (증가, 유지, 감소)
- **보상 (Reward):** 정확도 기반 피드백
- **정책 (Policy):** 상태 → 행동 전략


4. 강화 학습 & 결과

DQN 모델 아키텍처




4. 강화 학습 & 결과

Final Policy Reward Distribution (Boxplot)



Distribution of Final Policy Rewards (Validation)



>> 안정적인 보상 상승 및 높은 예측 정확도 달성



5. 기존 연구와의 비교

- 뇌종양 미래 부피 “예측” task는 현재 연구 자체가 많이 이루어지지 않은 분야
- 특히나 강화학습(DQN)은 기존에 종양의 위치 탐색에는 쓰였으나, – references [1]
뇌종양 진행 예측에 쓰여진 연구로 발간된 논문은 없는 것으로 확인됨
- 높은 예측 성능을 보이는 DQN 모델이 다른 연구들에 비해 경쟁력을 가질 것으로 보임

reference

[1] Stember and Shalu, "Reinforcement learning using Deep Q networks and Q learning accurately localizes brain tumors on MRI with very small training sets," BMC Medical Imaging 2022.



Q&A