

REPORT

뇌종양 진행률/예후 예측 (딥러닝 및 강화학습 기반)



과목명

캡스톤설계 및 실습

지도교수

장익범, Walid Abdullah Al

학과

컴퓨터공학부

팀원
(학번-이름)

202204495-홍창희
202101313-민휘원
202001564-박지호
201701679-배영민
202204529-손동희

제출일

2025.06.11

목 차

1. 서론.....	2
2. 데이터 및 전처리.....	2
2.1. 사용 데이터셋.....	2
2.2. 전처리 과정.....	2
3. CNN 모델 설계 및 결과.....	3
3.1. 모델 구조.....	3
3.2. 학습 방법.....	3
3.3. 실험 결과 및 분석.....	4
4. 강화학습(DQN) 모델 설계 및 결과.....	5
4.1. 모델 아키텍처.....	5
4.2. 학습 전략.....	6
4.3. 실험 결과 및 분석.....	7
5. 기존 연구와의 비교 및 결론.....	8
참고문헌.....	8

1. 서론

현재 대부분의 임상 현장에서는 단일 시점의 MRI 영상을 통해 뇌종양을 진단하고 평가하는 것이 일반적이다. 이러한 접근 방식은 종양의 현재 상태를 파악하는 데는 유용하지만, 잠재적인 성장 속도나 패턴을 알아내기 어려워 환자의 예후를 정량적으로 예측하는 데 한계가 있다. 본 프로젝트는 이러한 문제점을 해결하고자, 일정 기간 후의 종양 부피를 수치적으로 예측하여 뇌종양의 진행률을 파악하는 모델 구현을 목표로 하였다. 이를 위해 두 가지 차별화된 접근법, 즉 심층신경망(CNN) 기반의 회귀 모델과 강화학습(DQN) 기반의 예측 모델을 각각 설계하고 구현하였다.

2. 데이터 및 전처리

2.1. 사용 데이터셋

본 연구에서는 'Brain-Tumor-Progression' 데이터셋을 활용하였다. 이 데이터셋은 총 20명의 뇌종양 환자에 대해 각기 다른 두 시점에서 촬영한 MRI 이미지(FLAIR, T1, T1ce, T2)와 해당 종양 영역을 나타내는 마스크(Mask) 데이터를 포함하고 있다.

2.2. 전처리 과정


정확한 모델 학습을 위해 다음과 같은 데이터 전처리 과정을 수행하였다.

- 슬라이스 수 조절: 환자마다 22~25개로 다른 Z축 슬라이스 개수를 22개로 통일하여 데이터의 규격을 맞추었다.
- 리샘플링 (Resampling): 모든 이미지의 픽셀 간격을 1mm x 1mm x 1mm로 표준화하여 해상도를 일치시켰다.
- 정규화 (Normalization): 픽셀 값의 범위를 조정하고 정규분포에 가깝게 만들어 모델이 안정적으로 학습할 수 있도록 하였다.
- 정합 (Registration): 서로 다른 두 시점에서 촬영된 MRI 이미지 간의 각도, 크기, 위치 불일치를 해소하기 위해, 두 이미지를 동일한 좌표 공간상에 정렬시키는 정합 작업을 수행하였다.

3. CNN 모델 설계 및 결과

3.1. 모델 구조

첫 번째 접근법으로 멀티태스크 학습 구조의 CNN 모델을 설계하였다.



- **백본 네트워크:** 사전 학습된 ResNet-50 모델을 특징 추출을 위한 백본으로 사용하였다.
- **입력 채널 확장:** ResNet-50의 첫 번째 합성곱 레이어를 기존 3채널에서 5채널로 확장하여 FLAIR, T1, T1ce, T2, Mask 이미지를 동시에 입력받을 수 있도록 수정하였다. 확장된 채널의 가중치는 기존 3채널 가중치의 평균값으로 재초기화하였다.
- **멀티태스크 헤드:** ResNet-50의 완전 연결 계층(Fully Connected Layer)을 제거하고, 종양의 크기를 예측하는 'Size Head'와 성장률을 예측하는 'Growth Head'라는 두 개의 독립적인 회귀 헤드를 추가하였다.


3.2. 학습 방법

모델의 학습 효율과 성능을 높이기 위해 다음과 같은 전략을 적용하였다.

- **데이터 분할:** Group Shuffle Split을 사용하여 환자 단위로 데이터가 섞이지 않도록 train/validation/test 세트로 분할하였다.
- **데이터 증강:** Flip, Rotation 등 무작위 데이터 증강 기법을 적용하여 데이터의 다양성을 확보하였다.
- **가중치 샘플링:** 예측이 어려운 극단값(outlier)을 가진 샘플에 대해 더 큰 가중치를 부여하는 'Rare Sample Weighting'을 적용했으며, 코사인 스케줄러를 통해 학습이 진행될수록 이 가중치를 점진적으로 높였다.
- **손실 함수:** 크기 예측(Size Head)에는 MSELoss를, 성장률 예측(Growth Head)에는 HuberLoss를 사용한 멀티태스크 손실 함수를 정의하여 학습을 진행했다.

3.3. 실험 결과 및 분석

학습된 모델을 통해 예측된 부피 또는 성장량과 실제값을 비교한다. 예측 성능은 산점도와 추세선(이상적인 $y=x$ 직선)을 통해 시각적으로 평가한다.




1. **Size Prediction**에서는 전반적으로 예측값이 실제값을 따르나, 고부피 영역에서 다소 분산이 존재
2. **Growth Prediction**에서는 변화량에 대한 예측이 어느 정도 선형성을 가지나, 변화가 거의 없는 경우에는 감지가 다소 어려움

종양 크기와 변화량 모두에서 모델이 어느 정도 실제와 비슷한 값을 예측하고 있다. 작은 종양일수록 예측 정확도가 높으며, 부피가 크거나 변화량이 극단적인 경우는 오차가 커질 수 있다. 그래프 전체적으로 빨간 점선을 따르는 경향이 나타나며, 이는 모델이 일정 수준의 예측 가능성을 갖고 있음을 보여주는 긍정적인 결과이다.

4. 강화학습(DQN) 모델 설계 및 결과

4.1. 모델 아키텍처

두 번째 접근법으로, 뇌종양 부피의 순차적 변화 과정을 모델링하기 위해 강화학습(Reinforcement Learning, RL) 방법론을 도입했다. 본 연구에서는 DQN(Deep Q-Network)을 사용하여, 에이전트가 주어진 상태에서 보상을 최대화하는 행동을 학습하도록 설계했다.



DQN 기반 예측 시스템은 크게 '입력 및 특징 추출', '강화학습 환경', 'DQN 에이전트'의 세 가지 주요 구성 요소로 이루어진다.

- **입력 및 특징 추출:** 모델은 뇌종양의 상태를 나타내는 MRI 이미지(Flair, T1, T1ce, T2)를 입력으로 받는다. 이 이미지들은 사전 학습된 ResNet-50 CNN 모델을 통해 고차원의 특징으로 변환된다. 추출된 특징은 PCA를 통해 차원이 축소되며, 여기에 슬라이스별 통계 정보, 종양 부피의 변화 속도/가속도, 환자 메타데이터(나이, 성별 등)가 결합되어 최종적으로 43차원의 정형화된 특징 벡터(Feature Vector)가 생성된다.
- **강화학습 환경 (SlideMultiStepEnv):** 특징 벡터는 SlideMultiStepEnv라는 가상

환경으로 전달된다. 이 환경은 두 시점 간의 실제 종양 부피 변화 과정을 총 10개의 이산적인 스텝(step)으로 시뮬레이션한다. 각 스텝에서 환경은 에이전트에게 현재의 특징 데이터와 모델의 예측 볼륨을 포함한 43차원의 상태(State) 벡터를 제공한다. 에이전트는 이 상태를 기반으로 예측 볼륨을 미세 조정하는 세 가지 행동(Action), 즉 감소(-0.05), 유지(0), 증가(+0.05) 중 하나를 선택한다. 보상(Reward)은 마지막 스텝에서만 주어지는 희소 보상(sparse reward) 방식으로, 최종 예측 볼륨과 실제 볼륨 간의 차이를 기반으로 0.0에서 1.0 사이의 값으로 계산된다.


- **DQN 에이전트:** 에이전트는 DQN을 통해 주어진 상태에서 각 행동의 가치(Q-value)를 추정한다. Q-value 추정을 위한 Q-Network는 다층 퍼셉트론(MLP)으로 설계되었으며, 256, 128, 64개의 뉴런을 갖는 3개의 은닉층으로 구성된다. 이 네트워크는 43차원의 상태 벡터를 입력받아 세 가지 행동에 대한 Q-value를 각각 출력하며, 이를 통해 에이전트는 보상을 최대화하는 최적의 행동을 결정한다.

4.2. 학습 전략

모델의 안정적이고 효율적인 학습을 위해 다음과 같은 핵심 전략들을 적용하였다.

- **경험 리플레이 (Experience Replay):** 에이전트가 환경과 상호작용하며 수집한 경험(상태, 행동, 보상)을 리플레이 버퍼에 저장하고, 학습 시 무작위로 샘플링하여 사용했다. 이를 통해 데이터 간의 시간적 상관관계를 줄여 학습 안정성을 확보했다.
- **타겟 네트워크 (Target Network):** 학습 과정에서 Q-value의 타겟값이 급격하게 변하는 것을 방지하기 위해, 별도의 타겟 네트워크를 두어 일정 주기마다 가중치를 업데이트하는 방식을 사용했다. 이는 학습 불안정성을 해소하는 데 기여했다.
- **Adam 옵티마이저:** 최적화 기법으로 Adam을 사용했으며, 특히 학습률(learning rate)을 $5e-6$ 으로 낮게 설정하여 민감한 의료 데이터에 대해 세밀하고 안정적인 학습이 가능하도록 했다.
- **Huber 손실 함수:** 손실 함수로는 Huber Loss를 채택했다. 이 함수는 예측 오차가 클 때의 영향을 감소시켜 이상치(outlier)에 덜 민감하고, 모델이 더 강건하게(robust) 학습되도록 돕는다.

4.3. 실험 결과 및 분석



모델의 성능은 최종 예측 볼륨과 실제 볼륨의 정확도를 0.0에서 1.0 사이의 보상(Reward) 값으로 변환하여 평가했다. 보상 값이 1.0에 가까울수록 예측이 정확함을 의미한다.

결과 분석을 위해 보상 분포를 박스플롯(Boxplot)과 히스토그램(Histogram)으로 시각화했다.

- 보상 분포 (Boxplot): 박스플롯 분석 결과, 보상의 중앙값(median)은 약 0.8 부근에 위치하여 대부분의 예측이 높은 정확도를 보였음을 확인했다. 또한, 상위 75% 지점(upper quartile)이 0.9에 근접하여 상당수의 사례에서 매우 우수한 예측 성능을 달성했음을 알 수 있었다. 일부 낮은 보상을 받은 사례도 존재했지만, 전반적으로 모델이 안정적으로 높은 성능을 보임을 확인했다.
- 보상 분포 (Histogram): 히스토그램에서는 보상 값이 0.8에서 1.0 사이에 집중적으로 분포하는 것을 관찰할 수 있었다. 이는 대다수의 검증 사례에서 모델이 실제 볼륨 변화를 거의 완벽에 가깝게 예측했음을 의미한다. 반면, 보상 값이 0.0에 가까운 사례는 소수에 불과하여, 모델이 특정 케이스에 과적합되지 않고 전반적으로 높은 예측 성능을 유지하고 있음을 보여준다.

종합적으로, 두 결과 차트는 본 연구에서 제안한 DQN 기반 강화학습 모델이 실제 환자의 뇌종양 볼륨 변화 궤적을 높은 정확도로 예측하며, 안정적인 학습 성능을 성공적으로 달성했음을 입증한다.

5. 기존 연구와의 비교 및 결론

뇌종양의 미래 부피를 직접 '예측'하는 연구는 현재 활발히 이루어지지 않은 분야이다. 특히, 강화학습(DQN)을 뇌종양의 '진행 예측'에 적용한 연구는 문헌 조사 결과 보고된 바가 없는 것으로 확인되었다. 기존 연구[1]는 DQN을 종양의 '위치 탐색(localization)'에 사용한 사례는 있으나, 본 연구와 같이 진행률 예측에 사용한 것은 아니다.

따라서 본 프로젝트에서 개발한 두 모델, 특히 높은 예측 성능과 안정적인 학습 결과를 보인 DQN 모델은 뇌종양 예후 예측 분야에서 높은 경쟁력과 독창성을 가질 것으로 기대된다. 이는 향후 정량적 예후 예측을 통한 환자 맞춤형 치료 계획 수립에 기여할 수 있는 가능성을 제시한다.

참고문헌

[1] Stember and Shalu, "Reinforcement learning using Deep Q networks and Q learning accurately localizes brain tumors on MRI with very small training sets," BMC Medical Imaging 2022.